EVQ-Cosh 核心理论与关键实验整合报告

2026-03-05

1 核心结论

1. EVQ-cosh 将 RoPE 频率分配问题写成变分逆问题，给出闭式解，且 Geometric RoPE 是 $\tau \to 0$ 的退化极限。
2. 对任意 $L > 0$，$\tau^*(L) > 0$，因此 Geometric 在该解族中严格次优。
3. Waterbed 不等式给出全局代价下界；实验显示代价集中在短程小幅上升，而收益集中在长程显著下降，整体呈非对称收益结构。
4. $\tau^*(L) = d_{head}/\sqrt{L}$ 在多组文本实验（125M/454M、多 seed）上得到方向一致验证。
5. EVQ 与 YaRN 是正交维度：训练时频率优化与推理时长度缩放可叠加，出现超线性协同。
6. EVQ-cosh 的频率分配不仅适用于 1D text RoPE，也适用于 3D Video RoPE 的 temporal 维度，且 τ^* 预测在视频 temporal 维度上保持有效。

2 理论框架

2.1 六步闭环推导

1. 距离先验 $D(\Delta)$。
2. 相位碰撞核
$$K(\phi_1, \phi_2) = \int D(\Delta) \cos(b^{-\phi_1}\Delta) \cos(b^{-\phi_2}\Delta)\, d\Delta.$$
3. Broadband 投影
$$K \approx \alpha\delta(\phi_1 - \phi_2) + \beta \min(\phi_1, \phi_2),$$
对应算子形式 $\alpha I + \beta A^{-1}$。

4. 构造泛函

$$J[\rho] = \frac{\alpha}{2}\int \rho^2 + \frac{\beta}{2}\iint \rho\rho \min - \mu \int \rho b^{-2\phi}.$$

5. Euler–Lagrange 化为 ODE：

$$\rho'' - \tau^2\rho = \gamma b^{-2\phi}, \qquad \tau = \sqrt{\beta/\alpha}.$$

6. ODE 通解 + CDF 反演得到离散频率分配：

$$\phi_k(\tau) = 1 - \frac{1}{\tau}\operatorname{arcsinh}\big((1-u_k)\sinh\tau\big).$$

唯一核心近似位于第 2→3 步。其余环节为精确推导。

2.2 四个核心定理

Theorem 1（ODE 精确解）：最优密度由 hyperbolic tether 与 Fisher pulse 两项竞争构成，τ 控制平衡。
Theorem 2（零温极限）：$\tau \to 0$ 时 EVQ 光滑退化为 Geometric。
Corollary（严格次优性）：任意 $L > 0$，$\tau^* > 0$，Geometric 为连续最优解族中的退化点。
Waterbed 不等式：对数误差体积存在下界，Geometric 取最小体积但误差分布最不均匀。

3 物理解释与可解释性

3.1 关于 τ 的正确解释

τ 的作用不是“把频率推向低频端”，而是**重分配通道密度**：

- 低频端间距扩大（关键收益区）。
- 高频端间距压缩（主要承担可控代价）。
- 长程外推收益来自低频碰撞下降，而非单纯频率平移。

3.2 非对称 trade-off

实验观察到：短程代价通常是个位数甚至更小；长程收益可达到两位数至数十个百分点。该现象与“高频冗余较多、低频为长程瓶颈”的机制一致。

4 Scaling Law 与模型大小无关性

4.1 主公式

$$\tau^*(L) = \frac{d_{head}}{\sqrt{L}}.$$

4.2 验证摘要

L_{train}	预测 τ^*	实测最优趋势	备注
128	5.66	高 τ 更优	PE-dominant 区间
256	4.00	$\tau = 4.0 > 2.0$	125M 与 454M 一致
512	2.83	中高 τ 更优	方向一致
1024	2.00	约 2.0 最优	与预测对齐
2048	1.41	约 1.5 最优	与预测对齐

5 碰撞块分析与 base 依赖

5.1 核心表达

$$\Delta J \propto \frac{1-c}{\ln b}, \qquad c = \frac{\ln L}{\ln b}.$$

当 base 增大，$\ln b$ 增大且碰撞块比例变化导致净可优化空间上升。对应观察为：base=500K 的净增益显著高于 base=10K；base=10K 场景出现系统性负结果，与碰撞块理论一致。

6 r 参数结论

6.1 结论

r 不是主方法层面的必要超参数。Pure EVQ（r=0）在多组关键指标上已满足主张要求，且与 YaRN 组合时表现更稳定。

6.2 原因

EVQ-cosh 在高频端天然扰动很小（包含 $k = 0$ 通道与 Geometric 完全一致的严格点），因此“强制切分高频保留区”的额外机制并非必要条件。

7 文本实验主证据

7.1 350M，$L_{train} = 2048$，3-seed

- PPL@2K：约 +0.4%（几乎无代价）。
- PPL@16K：约 -13.3%（稳定收益）。

7.2 454M，$L_{train} = 256$，3-seed

- Raw：$\tau = 4.0$ 在 4×–32× 全面优于 $\tau = 2.0$。
- 32×：Raw 改善约 -37.5%。

8 EVQ + YaRN 协同

8.1 现象

在多个长度点，YaRN 对 Geo 的增益有限，但对 EVQ 基线的增益显著放大，体现为“同一推理时缩放策略，在更优训练时频率基础上获得更高杠杆”。

8.2 代表性数字

- 350M passkey：EVQ+YaRN@8K 达到 100%（多 seed 零方差），Geo+YaRN 明显更低。
- 454M，$L_{train} = 256$：EVQ4.0+YaRN 在 32× 约 -61.7%（对 Geo+YaRN）。

9 Video Temporal 证据（3D RoPE）

9.1 实验控制

- 数据：bouncing-ball 时序数据。
- 位置编码：3D RoPE，spatial 频率保持 geometric。
- 唯一改动：temporal 频率切片 `inv_freq_t` 使用 EVQ-cosh。

9.2 结果

- EVQ $\tau = 2.0$ 相对 Geo：4×/8× temporal extrapolation 的 raw PPL 改善约 +19% / +18%。
- EVQ+temporal-YaRN：4×/8× 改善约 +28% / +21%。

9.3 结论

EVQ-cosh 的频率分配跨模态成立：文本 1D RoPE 与视频 3D RoPE temporal 维度上，机制与趋势一致，τ^* 预测仍有效。

10 Capability-Preserving 与任务边界

10.1 保能力

纯 FineWeb-Edu 场景下，passkey 指标接近随机区间且 Geo/EVQ 差异接近噪声，支持“未学任务能力不被明显破坏”的陈述。

10.2 强增益

任务进入训练分布后（如 passkey mix），EVQ 在外推区间表现出显著强于 Geo 的检索能力，说明改进主要落在“已学能力的长度泛化”维度。

11 可直接落地的算法形式

$$\tau = \frac{d_{head}}{\sqrt{L}}, \qquad u_k = \frac{k+0.5}{K}, \qquad \phi_k = 1 - \frac{1}{\tau}\,\mathrm{arcsinh}\big((1-u_k)\sinh\tau\big), \qquad \theta_k = b^{-\phi_k}.$$

实现层面只需替换 inv_freq 初始化，不要求改模型结构与训练流程。

12 风险与边界

- Broadband 投影是关键近似，建议补 perturbation bound 进一步提高理论稳健性。
- 部分结果仍是单 seed，需要补多 seed 以稳固统计显著性。
- 下游任务仍需扩展到更贴近真实应用的基准。

13 下一步优先级

1. DSR（Distance-Swept Retrieval）完整曲线与统计检验。
2. Video temporal 多 seed 补全与显著性报告。
3. Broadband 误差界与 τ^* 推导严密化。
4. 统一主文图表：Raw/YaRN、Text/Video、理论/实验同轴展示。

14 结语

现有证据链已经形成“理论可解释 + 跨规模可复现 + 跨模态可迁移”的主干结构。当前的主要工作不再是寻找新故事，而是提升统计稳健性、补齐关键下游任务，并将已成型叙事压实为可投稿版本。