EVQ-Cosh：核心理论与关键实验说明

2026-03-06

这项工作从 RoPE 的频率分配问题切入，而不是把注意力集中在推理时如何继续缩放位置。现有长上下文方法大多默认 geometric RoPE 是一个足够好的训练底座，再在推理时叠加 PI、NTK-aware、YaRN 等长度缩放规则。EVQ-Cosh 的核心判断不同：如果训练时的频率分配本身已经把低频通道挤得过密，那么推理时继续缩放位置只会在错误的底座上做外推，真正的瓶颈仍然留在训练阶段。沿着这条思路，EVQ-Cosh 将 RoPE 频率分配重新表述为一个变分逆问题，并试图给出一个闭式、可实现、且与实验现象一致的频率分配公式。

一、理论主线已经站稳的部分

以 $\phi \in [0,1]$ 表示对数频率坐标、$\omega(\phi) = b^{-\phi}$ 表示角频率、$D(\Delta)$ 表示距离先验，则 phase-collision kernel 可写成

$$K(\phi_1, \phi_2) = \int D(\Delta) \cos(\omega(\phi_1)\Delta) \cos(\omega(\phi_2)\Delta) \, \mathrm{d}\Delta. \tag{1}$$

这一步仍是精确表达。后续唯一的核心近似，是把精确 kernel 压缩到一个可解析的 broadband surrogate：

$$\mathsf{K} \approx \alpha I + \beta \mathsf{A}^{-1}, \tag{2}$$

其中 $\mathsf{A} = -\partial_\phi^2$，$\mathsf{A}^{-1}$ 的 Green 核对应 $\min(\phi_1, \phi_2)$。一旦这一步固定，后面的变分泛函、Euler – Lagrange 方程、双曲函数型通解与反 CDF 频率分配链条都可以严格写出。

在这一 surrogate 下，频率密度 $\rho(\phi)$ 的目标泛函为

$$J[\rho] = \frac{\alpha}{2} \int_0^1 \rho(\phi)^2 \, \mathrm{d}\phi + \frac{\beta}{2} \int_0^1 \int_0^1 \rho(\phi)\rho(\psi) \min(\phi, \psi) \, \mathrm{d}\phi \mathrm{d}\psi - \mu \int_0^1 \rho(\phi) b^{-2\phi} \, \mathrm{d}\phi. \tag{3}$$

极小点满足常系数受迫 ODE

$$\rho'' - \tau^2 \rho = \gamma b^{-2\phi}, \qquad \tau = \sqrt{\beta/\alpha}, \tag{4}$$

其通解由双曲 tether 与 Fisher forcing 两部分组成：

$$\rho^*(\phi) = C_1 \cosh(\tau\phi) + C_2 \sinh(\tau\phi) + P b^{-2\phi}. \tag{5}$$

在最干净的 pure-tether 设定下，CDF 可显式反演，从而得到直接替换 `inv_freq` 的闭式公式

$$\phi_k(\tau) = 1 - \frac{1}{\tau} \operatorname{arsinh}\big((1 - u_k) \sinh \tau\big), \qquad u_k = \frac{k}{K}. \tag{6}$$

这条理论链最关键的结论，是 geometric RoPE 并不在 EVQ 家族之外。令 $\tau \to 0$，由 $\sinh \tau \sim \tau$ 和 $\operatorname{arsinh}(x\tau)/\tau \to x$ 可得 $\phi_k(\tau) \to u_k$，也就是标准 geometric 的均匀分位点。换句话说，geometric RoPE 不是另一种原则，而是 EVQ 家族中的零温退化点。这个结论将“EVQ 是否只是另一个位置编码技巧”的问题改写为“geometric 是否只是更大最优族中的一个退化极限”。

另一个必须同时保留的结构是 waterbed。不考虑其具体实现形式，仅从误差再分配角度看，EVQ 的收益不是无代价的；它的作用机制是把高频段的冗余压缩掉，用以缓解真正决定长程外推的低频碰撞。这也是当前实验中经常看到“短程变化很小、长程改善很大”的理论基础。

二、理论上需要保守处理的几点

严格版理论文稿给出的最大帮助，不是推翻这条主线，而是把边界划得更清楚。当前需要保守处理的点主要有五个。

第一，$\mathsf{K} \approx \alpha I + \beta \mathsf{A}^{-1}$ 这一步仍然是整条理论中的唯一近似，而且在连续模型里更适合被解释为算子层面的建模约定，而不是直接说成对 $\alpha\delta + \beta \min$ 的 Hilbert – Schmidt 投影。原因是连续情形下的 δ 对应恒等算子 I，并不是普通 L^2 核。严格说法应当是：正文把这一步当作唯一 surrogate，附录或后续工作再去补它与精确 kernel 之间的扰动界。

第二，目标泛函真正严谨的写法需要连同函数空间、边界条件和正性约束一起给出。若把 ρ 解释为概率密度，则最小化问题的可行域并不只是一个仿射空间，还包含 $\rho \geq 0$ 的约束；严格版本中，这意味着 Euler – Lagrange 方程只直接适用于严格正的内点极小解，更一般的情形需要通过 KKT 条件补齐。现有正文主线默认工作在内点解 regime，这是合理的，但这层假设需要明确说出。

第三，若把 $\mathsf{A} = -\partial_\phi^2$ 与混合边界条件一起完整写出，则 $\min(\phi, \psi)$ 作为 Green 核这件事可以严格成立。相应地，ρ^* 的存在唯一性也应建立在 $\alpha > 0$ 带来的强凸性之上，而不是只从 ODE 形式直接推出。这个修正不会改变结论方向，但能避免“公式写对了、函数分析地基没写”的问题。

第四，waterbed 型不等式在严格写法里需要额外假设 $E(\phi) > 0$ 且 $\ln E$ 可积。只要这两个条件写清楚，原有结论仍然可保留；如果不写，就容易在技术细节上留下漏洞。

第五，$\tau^*(L) = d_{\text{head}}/\sqrt{L}$ 目前仍应视为经验规律或条件性结论，而不是无条件定理。现有实验对它的支持已经很强，尤其是 $L = 256$ 的 Phase 11 直接确认了 $\tau = 4.0$ 优于 $\tau = 2.0$，但这和“理论上已经完全证明其标度律”仍然是两回事。严格版文稿给出的正确处理方式，是把它降格为 empirical law / conjecture，同时把短长度区间的偏差归因于 PE-dominant regime 与模型容量因素。

三、这套理论在机制上解释了什么

如果只从实现层面看，EVQ 似乎只是把一组 `inv_freq` 换掉；但理论真正解释的不是“换了一组数字”，而是通道密度如何被重新分配。这里最容易说错的一句话，是“τ 把频率推向低频端”。这个说法并不准确。更严格的描述是：$\tau > 0$ 之后，每个 ϕ_k 会向高频端偏移，但真正重要的效应不在位置本身，而在相邻通道的间距重新分布。低频端间距被拉开，高频端间距被压缩，因而长距离最关键的低频碰撞被缓解，而高频段承担了 waterbed 代价。

这一点解释了为什么实验中常见的形状不是“短程和长程一起线性改进”，而是“短程基本不变，长程明显改善”。在当前自然语言设定下，高频近程往往已经存在相当冗余，相邻通道编码的信息高度相似；低频端则更像瓶颈，一旦发生相位碰撞，模型对超出训练长度的远程依赖几乎失去区分能力。因此 EVQ 的本质不是平均地优化所有频段，而是把资源从相对冗余的高频端转移到真正限制外推的低频端。

这也正是 collision-block 分析的价值所在。若某个频率通道对应的波长已经长到超出训练长度，它在训练阶段就无法被充分分辨。随着 base 变小，可真正被优化的通道数会显著减少，因此 EVQ 的净收益会迅速进入 dead zone。现有 $base = 10\text{K}$ 的负面结果正好说明了这一点：当可优化通道太少时，EVQ 不但难以带来收益，甚至会显式退化。这个负面结果并不削弱理论，反而是理论在一个极端边界条件下的确认。

另一条机制层面的结论是：r 并不是一个真正需要调的核心超参数。早期 Hybrid 思路试图只对一部分频段做局部 warp，但后续理论与实验都表明，EVQ-Cosh 的闭式解天然就保持了最高频端的锚定：$k = 0$ 时有 $\phi = 0$，最前几个通道的改变量本来就极小。也就是说，“高频不动、低频重分配”已经内含在闭式解里，不需要再靠人为指定 r 去硬切频段。后续 r-sweep 和 EVQ+YaRN 的结果也都支持这一点：Pure EVQ 是更干净、更稳定的主方法。

四、目前最硬的实验事实

当前最强的系统级结论不是 EVQ 单独优于 Geo，而是 **EVQ 明显放大了 YaRN 的作用**。在 10% passkey mix、fair scale = 8 的三种子比较中，EVQ+YaRN 在 8K retrieval 上达到 100%，而 Geo+YaRN 只有 61% ~ 65%；PPL@8K 为 70.9 对 82.9，PPL@16K 为 107.5 对 157.7。这组结果的含义不是"训练时与推理时两个方法叠加后数值更大"，而是它明确揭示出一个结构性事实：推理时长度缩放的上限，取决于训练时频率底座是否先被做对。

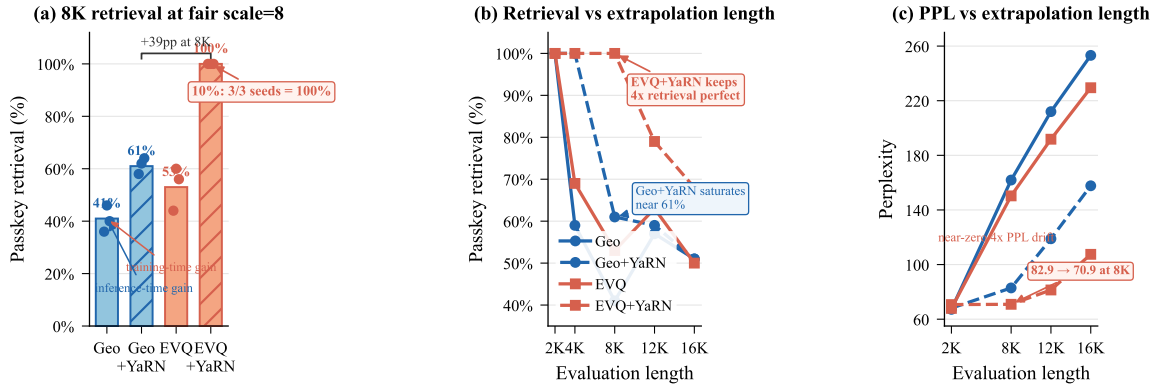

Figure 1: 当前最强的系统级结果。核心信息不是 EVQ 单独优于 Geo，而是 EVQ 作为训练时频率底座，显著放大了 YaRN 的推理时外推效果。

第二条硬结果来自 DAPE 风格的极端外推设定。模型只在 128 token 上训练，却要外推到 8K。在这个 regime 中，模型权重来不及学会复杂的位置补偿，因此结果更直接地反映位置编码本身的质量。当前数值是 geometric 的 PPL@8K = 513.7，DAPE 为 455.3，EVQ 为 333.7。这说明在极端外推场景下，闭式频率分配不仅优于 geometric，也优于 learnable PE；EVQ 的优势不是来自额外可学习参数，而是来自频率本身分配得更合理。

第三条核心结果是 Phase 11。在 454M、$L_{\text{train}} = 256$、三种子设定下，理论预测的 $\tau = 4.0$ 全面优于 $\tau = 2.0$；加上 YaRN 后，$\text{EVQ}_{\tau=4.0} + \text{YaRN}$ 在 32× 外推处达到 99.6，而 Geo+YaRN 为 260.2，相对下降 −61.7%。与此同时，YaRN 对 Geo 只带来 3 – 5% 改善，但对 EVQ 可带来 33 – 41% 改善，杠杆效应接近 10×。这一组数据把理论和系统级结论真正粘合在一起：τ^* 不是事后拟合出来的单点参数，而是能够在新的 PE-dominant regime 中继续给出正确方向；EVQ×YaRN 的协同也会在训练长度更短、低频碰撞更严重时进一步放大。

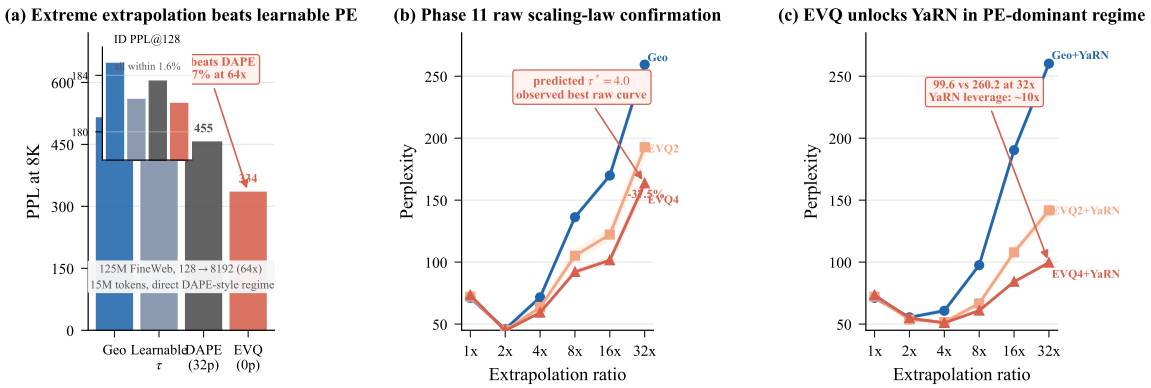

Figure 2: PE-dominant 设定中的双重验证。左图对应 DAPE 风格的极端外推，右侧两图给出 $L = 256$ 的 raw 与 YaRN 结果。它们共同说明：闭式频率分配不仅能在极端外推中胜过 learnable PE，也能在更大模型中给出正确的最优方向与协同强度。

第四条是更常规、但同样重要的稳健性结果。在 350M、$L_{\text{train}} = 2048$、FineWeb-Edu 三种子设定下，EVQ 在 2K 的代价只有 +0.4%，但在 16K 上可把 PPL 从 284.8 降到 246.9，相对改善

-13.3%。这说明 EVQ 不是只在极端 toy regime 里成立；即使回到更常规的训练长度，它仍然保持了“短程代价很小、长程收益明确”的形状。

第五条是 capability-preserving 方向的证据。纯 FineWeb-Edu 下，passkey 对 from-scratch 小模型几乎是随机任务，Geo 与 EVQ 表现没有显著差异；而一旦在训练中显式混入 retrieval 模式，EVQ 在外推长度上的优势就稳定出现。在 10% passkey mix、三种子平均下，EVQ 相对 Geo 在 4K retrieval 上提升 +10.0 个百分点，在 8K 上提升 +12.7 个百分点。这说明 EVQ 并不是无条件地提升一切能力，而是在已有任务能力被学会之后，显著改善其长度泛化。

此外还有两类结果值得保留，但当前不宜放到最前面。第一类是 750M 模型在训练长度继续拉到 4K 之后的结果。在 full EVQ、2K $\rightarrow$ 4K continue 的设定下，16K PPL 从 45.1 降到 24.4，8K 的 AR exact 从 0% 升到 77.5%。这表明随着训练长度和 token 增大，EVQ 的长程收益没有被洗掉；但由于它目前还是 single-seed，最稳妥的身份仍然是 supporting evidence。

第二类是 video temporal transfer。当前控制实验表明，在保持 spatial 频率全 geometric、只替换 temporal slice 时，EVQ 与 temporal-YaRN 的协同仍然明显存在。这说明该机制并非 text-only artifact，但视频证据目前还不足以取代文本主线。

五、当前最稳妥的结论

截至目前，最稳妥的总结合理地分成两层。第一层是理论层：RoPE 的频率分配确实可以写成一条完整的变分主线，surrogate 固定后，ODE、双曲函数型最优密度、反 CDF 频率分配、以及 geometric 作为 $\tau = 0$ 退化点这几件事是同一条链上的结果。第二层是实验层：在当前最强的系统设定里，真正抓住问题本质的不是“EVQ 单独 raw PPL 更好”，而是“训练时频率优化决定了推理时长度缩放能否真正发挥作用”，这就是 EVQ+YaRN 显著优于 Geo+YaRN 的原因。

因此，当前最适合保留在主叙事中的一句话是：**EVQ 的本质不是把频率简单推向某一端，而是重分配通道密度，通过压缩高频间距、扩大低频间距，缓解真正决定长程外推的低频碰撞；而这一点恰好解释了为什么 EVQ 能显著放大 YaRN 的作用。**

六、仍待补齐的部分

需要继续补齐的地方也很明确。理论上，broadband surrogate 与精确 kernel 之间的扰动界仍未给出；$\tau^*(L)$ 的标度律仍需更紧的证明；若要把密度问题写到完全严格，还应把非负性约束与 KKT 条件整合进正文或附录。实验上，真实下游任务上的 clean win 还不够多，目前最强证据仍集中在长上下文检索与 PE-dominant 外推；750M continue 和视频 temporal 的结果都很有价值，但现在更适合作为 supporting evidence，而不是 primary anchor。

在这个边界之内，现有结论已经足够清楚：EVQ-Cosh 并不是另一个孤立的位置编码技巧，而是一条从频率分配问题出发的完整理论与实验路线。它已经给出了解释 geometric 退化性的方式，也已经在极端外推、PE-dominant regime 和 EVQ$\times$YaRN 组合上拿到了很强的经验支持；需要继续补的，是严格性边界和更强的下游锚点，而不是主线方向本身。